

정산서 파서 구현 버전 히스토리

대상: 하이브마인드 정산 표준화 솔루션(settlement-app)의 유통사 정산서 파서·산식 원칙: 유통사 정산서는 양식·명명·제공방식이 수시로 바뀌므로, 데이터가 추가될 때마다 파서를 확장하고 **1~4월 회귀검증(무변경)** 을 통과시킨 뒤 반영.

0. 파서 공통 구조

- **형식 판별**: 매직바이트로 실제 형식 판별 (HTML 위장 .xls, 깨진 xlsx, cp949 인코딩, zip 등 확장자와 무관하게 처리)
- **플랫폼 매칭**: 파일명 정규식 → 스펙 선택 (`find_spec`)
- **헤더 위치**: 고정행 `header=(a,b)` 또는 `header_find` (토큰 자동탐지). 그룹 헤더는 그룹/디테일 로 평탄화
- **컬럼 매핑**: 표준 필드(title·author·label·gross·settle·book_type...)에 후보 컬럼명 리스트를 이름 기준으로 매핑 (위치 불변 가정 안 함)
- **산식(calc)**: 매출·정산액 미제공 플랫폼은 `gross_calc` · `settle_calc` 로 계산, `basis` 플래그로 제공값/계산값 구분
- **검증**: 플랫폼 자체 합계행과 대사 (±1원 PASS)

1. v1 — 초기 (2·3월) · 2026-06-10 · 스펙 30종

데이터: 유통사 28~29곳의 26년 2·3월 정산서 69파일 (본부장 최초 제공분).

파서: - 유통사 25종 컬럼 → 표준 항목 매핑. HTML 위장 .xls 16종, 깨진 xlsx(북큐브·애니툰), cp949, zip(리디) 전부 처리 → 145,018행 표준화.

산식(정산액/매출 미제공처 계산): - 네이버서리즈: 정산액 = (합계 - 마켓수수료추정) × 0.7 - 미스터블루: 판매유형별(정액+종량) 정산액 합산 - 리디: 매출 = 판매액 + 취소액 / 조아라: 매출 = 단가 × 판매건수 / 블라이스: 정산액 = 판매액 × 0.7

검증: 40개 파일 합계행 전수 일치.

2. v2 — 고도화 (1~4월) · 개발 2026-06-19 / 배포 06-26 · 스펙 +7

추가 데이터(본부장 제공): 1·4월 완전판 + 과거 '취합 불가'였던 교보문고·모픽 + 에이블리 2·3월.

파서 추가/수정: - 모픽·교보문고 스펙 신규 (교보 = B2B 기관납품, ISBN·공급사 보유 → 매칭키 자산) - 노벨피아 (1) detail 양식 매칭 추가 - 명명 변경 수용: 원스토어(←원스토리), 오망띠끄_연재 / 로망띠끄_전자책, 알라딘 B2B(도서명·정가합 양식)

산식(2026-06-15 반영): - 예스24: 매출 = 총정산액 ÷ 0.7 (매출 미제공 → 역산) - 판무림: 정산액 = 판매금액 × 0.7 (행단위 정산액 미제공) - E2 작가 정규화 강화 (한자·영문 병기 통합)

검증: 151파일 431,296행, 대사 86 PASS·0 FAIL, 완전매칭 99.5%.

3. v2.1 — 11~12월 (이번) · 2026-07-01 · 스펙 +7 → 37종

추가 데이터(본부장 제공, 6/24~25): 25년 11~12월 정산서 163파일(정산서 샘플 3) + 일매출 트래킹 샘플 + 작가 정산서 샘플. 일부 플랫폼의 양식·명명·제공방식이 변경됨.

파서 수정/추가:

플랫폼	무엇이 바뀌었나	대응
예스24	1종 → 3종 신양식(B2B 기관납품 / B2C 소매 / 연재). 파일명이 B2B_List · B2C_List · SerialWorkStatisticsList	3종 스펙 신규 + 파일명 접두 매칭. 정산액 직접 제공 → ÷0.7 산식 폐기(구양식은 폴 백 유지)
카카오페 이지	구양식(헤더 6~7행)으로 1~4월(1~2행)과 상이	header=(1,2) → header_find 자동탐지로 구·신 통합 처리
네이버시 리즈·미 스터블루	ID/PW 변경 → 월정산서 대신 일매출(일별) 제공	일별 스펙 신규(파일명=YYYYMMDD / 작 품별정산_YYYY-MM-DD). 정산액 직접 제 공, 월 집계 전제
로망띠끄	명명 (로망띠끄 N월 1/2) 로 변경	매칭 확장(1=단행본/전자책, 2=연재). 컬럼 은 기존과 동일
노벨피아	일별 판매형(상품명·판매합계·정산금액·연재단행)	detail 매칭에 일별 포함(월별 조회수형은 정산금 0으로 기존 유지)

검증: 11~12월 163/163 파싱, 대사 31 PASS·0 FAIL / 1~4월 회귀 431,296행·86 PASS 불변(무회귀).

4. 산식(계산값) 이력 요약

플랫폼	산식	도입
네이버시리즈	(합계 - 마켓수수료추정) × 0.7	v1
미스터블루	판매유형별 정산액 합산	v1
리디	판매액 + 취소액	v1
예스24(구양식)	매출 = 총정산액 ÷ 0.7	v2 (6/15)
판무림	정산액 = 판매금액 × 0.7	v2 (6/15)
예스24(신 B2B/B2C/연재)	정산액 직접 제공(산식 불요)	v2.1
네이버·미스터블루 일매출	정산액 직접 제공	v2.1

5. 현재 커버리지 · 교훈

- 스펙 37종 / 유통사 31곳+ / 1~4월 431,296행(86 PASS) + 11~12월 163파일(31 PASS).
- 교훈: 유통사 정산서는 양식·명명·제공방식이 수시로 바뀐다. 파서는 ①파일명 정규식 매칭 ②헤더 자동탐지 ③이름 기준 컬럼 매핑 ④합계행 대사 4중 구조로 변화에 견디게 설계. 매 데이터 수령 시 회귀검증(1~4월 불변) 필수.
- 남은 통합 과제: 11~12월 일별 파일(네이버·미스터블루·노벨피아)의 월 집계(period 부여) 및 스냅샷/프로덕션 반영은 별도 단계.

작성: 2026-07-01 · settlement-app(git: rachelchoi11/hivemind) 기준 · 커밋 3759f53