

정산 프로그램은 어떻게 만들어졌나

부제 유통사별 제각각인 정산서 → 작가별 정산·근거 자동 산출까지

수신 하이브마인드

작성 최혜윤 · 2026. 6. 9.

유통사 28곳이 보내는 형식·표기가 전부 다른 정산서를, "작가에게 얼마를 왜 줘야 하는지"가 자동으로 나오는 하나의 표준 데이터로 만든 과정입니다. 각 단계에서 마주친 실제 문제와 해결 방법을 정리했습니다.

정산서 업로드 → ① 형식 통일 → ② 항목 통일 → ③ 작품·작가 자동 매칭 → ④ 미매칭 줄이기 → 작가별 정산·근거·통계·정산서 발행

1. 첫 번째 벽 — 파일이 파일이 아니었다 (형식 통일)

문제. 유통사마다 정산서 형식이 전부 달랐고, 확장자가 실제 형식과 달랐습니다.

실제 상태	해당 유통사 / 내용
확장자는 .xls인데 실제로는 HTML 문서 (16종)	네이버·노벨피아·무튼·밀리·블라이스·하이북 등 — 엑셀로는 열리나 프로그램으로 안 읽힘
.xlsx인데 내부가 깨진 비표준 파일	북큐브·애니툰 — 일반 라이브러리 오류
글자 인코딩(cp949) 상이	로망띠고·신영미디어·에피루스 — Mac에서 한글 깨짐
깨진 HTML / zip 압축	피플앤스토리(태그 누락) · 리디(zip)

해결. 확장자를 믿지 않고 **파일 첫 바이트(매직바이트)로 진짜 형식을 판별**하게 했습니다. HTML이면 HTML로, 깨진 xlsx는 깨진 부분을 갈아끼우는 관용 로더로, cp949는 자동 감지해 복원했습니다. 결과적으로 **69개 파일 전부 한 가지 표준 표로 변환**에 성공했습니다.

2. 두 번째 벽 — 같은 정보를 다른 이름으로 (항목 통일)

문제. "작가"를 어디는 작가명, 어디는 저자, 어디는 글작가로 부르고, "정산액"도 정산금액·소득액·총지급액·공급대가처럼 12가지로 제각각이었습니다.

해결. 유통사 25종 각각의 **컬럼 이름을 표준 항목(작품명·작가·레이블·총매출·정산액·구분)으로 매핑**하는 규칙표를 만들었습니다. 위치가 아니라 이름 기준이라 양식이 조금 바뀌어도 건드립니다.

- 합계행(합계·SUM·Total)은 제거하되, 그 합계로 **우리 계산이 맞는지 자동 검증**(합계 보유 40개 파일 전수 일치)에 재활용.
- 정산액을 안 주는 유통사는 산식으로 계산하고(예: 네이버 = (합계-수수료)×0.7), "**제공값/계산값**" 꼬리표를 붙여 추적 가능하게 함.

3. 핵심 벽 — "월야환담 28권"과 "29권"은 같은 작품인가? (자동 매칭)

이 프로젝트의 진짜 어려움이었습니다. 같은 작품·같은 작가인데 유통사마다 표기가 전부 달랐습니다. 원문을 그대로 비교하면 15.8%만 일치했습니다.

3-1. 작품명 통일 — 표기 차이를 기계적으로 제거(정규화)

문제 표기 (유통사별)	제거 규칙	결과
보스 오빠, 살살! ↔ 보소오빠, 살살!	띄어쓰기 제거	같은 작품
21세기 대마법사 10 / 회귀의 전설 3부 1222화	권·화·부 번호 제거	21세기 대마법사 / 회귀의 전설
[e북] · [단행본] · (개정판) · *세트구매*	태그·괄호 제거	본 제목만
술탄(Sultan) / 퇴마사(巫堂)	괄호 병기 제거	술탄 / 퇴마사
월야환담 28권 : 광월야 / 29권 : 광월야	제목 중간 권번호까지 제거	둘 다 = 월야환담 광월야

원문 그대로

15.8%

→

정규화 1차

65.6%

→

정규화 2차

78.8%

※ 단, '월야환담' 본편 / '광월야' / '채월야'처럼 부제가 다르면 별개 작품으로 유지 — 무리하게 합치지 않습니다.

3-2. 작가명도 똑같이 — [정천] = 정천

작가명도 [정천]과 정천, 이윤정(탠저린)과 이윤정 (탠저린)이 다른 작가로 잡혔습니다. → **대괄호·공백을 제거해 통일**. 작가 수가 4,310 → 4,251명으로 정리(중복 59명 병합)되었습니다.

3-3. 누락된 작가를 다른 유통사에서 끌어오기 — 당월 상호대조

작가를 안 주는 유통사(무튼·문피아·예스24 등)가 많았습니다. 핵심 아이디어는 "같은 작품을 작가까지 주는 다른 유통사가 있으면 거기서 끌어와 채운다"입니다.

예: '월야환담'을 예스24는 작가 없이, 알라딘·노벨피아는 '홍정훈'으로 제공 → 알라딘 정보로 예스24 빈칸을 채워 완전 매칭. 여기에 2022년 수작업 정리본(38,063행)을 초기 자산으로 승계 → 그동안의 수작업이 버려지지 않고 시스템의 시드가 됩니다.

결과: 작가·레이블 자동 완전매칭 98.1%.

4. 마지막 벽 — 미매칭 %를 계속 낮추기

조치	무엇을 했나	효과
① 번들 분리	‘원스토리 패스’ 같은 구독 상품은 작품이 아니므로 분리 (단, ‘삼국지 싸이코패스’ 같은 실제 작품 오인 방지 위해 정밀 패턴만)	정산액 미매칭률 0.42% → 0.20%
② 권 번호 통합	월야환담 28권/29권 통합 → 한쪽에 있던 작가가 전체에 적용	미매칭 작품 151 → 119
③ AI 제안	유사 작품·시리즈 형제작(광월야↔채월야)·오타(바래↔바라)에서 작가를 찾아 신뢰도·근거와 함께 제안 → 승인	근거 있는 건 자동 제안
④ 알라딘 조회	단서가 전혀 없는 단독 유통작은 알라딘 도서 DB에서 작가·ISBN 조회 → 제안	신수의 주인→태선, 습기→마태 등 확보

핵심 원칙. AI·외부조회는 근거 있는 것만 제안하고, 단서 없는 건 추측하지 않고 담당자 승인으로 넘깁니다. 틀린 작가에게 정산되는 것을 막기 위해 **무엇도 자동 적용하지 않으며**, 모든 승인·거절은 히스토리로 기록(감사 추적)됩니다.

5. 그래서 지금 무엇이 되나

- 작가별 정산액 + **왜 그 금액인지**(어느 유통사·작품·산식) 근거 추적
- 작가별 **정산 명세서 발행**(원천징수·실지금액 포함)
- 유통사별·작품별·통계(차트) 분석, 통합 검색
- 미매칭은 AI·알라딘 제안 → 승인으로 **계속 줄어드는 구조** (한 번 등록하면 이후 자동)

미매칭 % 진행 요약. 원문 그대로 15.8% → 정규화 78.8% → 당월 상호대조·시드로 완전매칭 98.1% → 번들·권통합·AI·알라딘으로 미매칭 정산액 0.2%대까지 축소, 운영하며 계속 하락.